

1.

MSE with different window size and step

	(10,15)	(5,10)	(15,20)	(5,20)
MSE	254.101151	118.871391	1107.319336	611.114441

在實驗中，使用不同的 window size 和 step 設定進行訓練，結果顯示 (5, 10) 設定的 MSE 最低，表現最佳。這表明較小的 window size 和較短的 step 更適合捕捉該數據集的短期變化。相較之下，(15, 20) 設定的 MSE 最高，可能因為過大的 window 無法準確捕捉短期波動。總結來看，較小的步長和窗口尺寸有助於提升預測準確度。

2.

(1) 在引入 Volume 作為額外輸入特徵後，使用 window size = 5 和 step = 10 訓練模型，觀察到 MSE 上升至 1357.412109。這顯示 Volume 可能並未對模型預測帶來顯著提升，反而導致模型預測誤差增大。可能原因是 Volume 與股價的關聯性不如預期，或模型未能有效處理這一新增特徵。

(2)

MSE with different feature

	Open,High,Low,Close	Open,High,close	Open,High	High,Low
MSE	118.871391	119.551376	143.040863	128.106781

根據不同特徵組合的 MSE 結果，使用 Open High Low Close 特徵組合的模型表現最佳，MSE 為 118.871391。相比之下，使用 Open High Close 特徵組合的模型 MSE 略高，為 119.551376。這表明加入更多的特徵（如 Low）有助於改善預測準確度。其他兩個特徵組合 Open High 和 High Low 的 MSE 更高，分別為 143.040863 和 128.106781，可能因為這些組合無法充分捕捉價格波動的多樣性。因此，Open High Low Close 是較為有效的特徵組合。

3.

MSE with and without normalized

	without normalized	with normalized
MSE	100.899208	104.366325

在比較有無正規化的情況下，模型的 MSE 結果顯示，無正規化的 MSE 為 100.899208，而 正規化後的 MSE 為 104.366325。這表明在這次實驗中，無正規化的模型表現略優於正規化的模型。正規化通常有助於加速模型收斂，但在某些情況下，可能因為資料特徵之間的關聯性較弱或異常值的影響，導致正規化後模型表現不如預期。

4.

在 Lab 4 中，window size 應小於 step size，以避免訓練過程中使用重複的資料點。這樣可確保每次訓練使用新的資料窗口，避免過度重複學習相同的資料，從而提高模型泛化能力。[source](#)

5.

在時間序列資料增強中，隨機時間扭曲（Time Warping）是一種有效的增強方法。此方法透過隨機地拉伸或壓縮時間軸，模擬時間序列中可能出現的時間延遲或提前，從而生成多樣化的訓練樣本，提升模型的泛化能力。

例如，Zhao 等人提出的 Dominant Shuffle 方法，通過對主導頻率成分進行隨機重排，保留了時間序列的主要結構，並有效提升了預測準確度。[source](#)

6.

(1)卷積模型 (CNN)：卷積模型通常適用於固定大小的視窗，因此在推理時，window size 可以直接設置為卷積層的過濾器大小。卷積層會學習到局部時間序列模式，這對於捕捉時間序列中的局部特徵非常有效。

(2)循環神經網絡 (RNN)：RNN 更適合處理長期依賴關係，window size 通常表示模型在訓練時回顧的時間步數。在推理過程中，RNN 會逐步處理時間序列中的每個步驟，因此可以根據需求調整 window size，以適應不同的序列長度。

(3) Transformer 模型：Transformer 利用自注意力機制，能夠並行處理整個序列。推理過程中，window size 可以根據輸入的長度來調整，並且自注意力機制可以處理更長的時間範圍，而不會受到固定視窗的限制。